

媒体与认知课程上机作业 2026：基于SigLIP的小规模图文检索系统

本次作业要求同学们使用SigLIP模型，完成一个小规模图文检索系统的训练、验证和测试。

项目背景

多模态学习（Multimodal Learning）是当前人工智能领域的研究热点，其中视觉与语言的融合任务，如图文匹配、图文检索、图文生成等，具有广泛的应用前景。

CLIP（Contrastive Language-Image Pretraining）是 OpenAI 提出的多模态预训练方法，利用图像-文本对比学习，使模型能自动将图像和文本嵌入到同一语义空间中，进而支持多种下游任务。然而该方案存在诸多问题，如强依赖大 batch size。


SigLIP（Sigmoid Loss for Language-Image Pretraining）是由 Google Research 提出的一种视觉-语言预训练方法，是对经典对比学习框架（如 CLIP）的重要改进。

任务目标

1. 理解 CLIP 与 SigLIP 在损失函数上的差异。
2. 使用Pytorch实现图像编码器、文本编码器和 SigLIP 损失函数。
3. 在 Flickr8k 数据集上训练模型，并报告 Text-to-Image 与 Image-to-Text 的 Recall@1/5/10。
4. 分析模型在多模态语义对齐方面的效果及可视化结果。
5. 基于 google/siglip-base-patch16-224 预训练模型，体验图文跨模态对比学习的核心结果——图文交叉相似度矩阵(代码在visualization/)。

技术路线与方法

1. 数据及选择：使用 Flickr8k 数据集，数据格式为图像 + 文字描述（1-5 条）。数据集下载可通过清华云盘链接：<https://cloud.tsinghua.edu.cn/f/6e5dcf45eac345649665/> 请将文件下载后放在\Flickr8k\images 目录下



- o 图像编码器【Task1】
 - 使用 ResNet18 进行特征提取，输出特征向量。
 - 添加线性层映射到共享语义空间。

- 文本编码器【Task2】

- 使用 MLP 或 Transformer 提取文本表示。
- 线性层将文本特征映射到相同维度的共享空间。

- SigLIP损失函数【Task3】

- SigLIP Loss (Sigmoid-based)

设图像编码为 z_i^I ，文本编码为 z_j^T ，相似度仍采用余弦相似度：

设一个 batch 中包含 $|\mathcal{B}|$ 个图文样本对，图像编码为 x_i ，文本编码为 y_j ，二者的相似度定义为：

$$z_{ij} = \frac{x_i^\top y_j}{\|x_i\| \|y_j\|}$$

其中， t 为可学习的温度系数， b 为可学习的偏置项。定义图文匹配标签为：

$$s_{ij} = \begin{cases} +1, & i = j \\ -1, & i \neq j \end{cases}$$

则对于任意一对 (i, j) ，SigLIP 的成对损失为：

$$\mathcal{L}_{ij} = \log(1 + \exp(s_{ij}(-tz_{ij} + b)))$$

因此，整个 batch 上的 SigLIP 损失为：

$$\mathcal{L}_{\text{SigLIP}} = \frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}|} \mathcal{L}_{ij}$$

即

$$\mathcal{L}_{\text{SigLIP}} = \frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}|} \log(1 + \exp(s_{ij}(-tz_{ij} + b)))$$

- 同学们完成代码中 ResNet、Transformer 模型的搭建以及SigLIP损失函数的编写，即可开始训练

3. 训练流程

1. 图像 + 文本 输入模型
2. 提取图像特征 / 文本特征
3. 归一化后计算余弦相似度矩阵
4. 计算损失并反向传播
5. 每轮评估 Top-K Accuracy / Recall@K 检索准确率，保存最优模型（此处需要同学们在 train_siglip.py 中修改）

4. 结果分析与可视化

1. 列出模型训练结束后的性能指标：Top-1 Accuracy / Recall@K
2. 请编写文本 → 图像 Top-K 检索示例的可视化代码，例如：



3. 结合模型训练结果和可视化分析的情况，尝试分析模型在文图检索任务上的表现，比如对文本描述或者图像类型是否存在偏好，预测结果好/不好可能的原因是什么，哪些方向可以进行改进等等

文件说明

- `train_siglip.py`: 完整训练、验证、测试入口。
- `loss.py`: SigLIP pairwise sigmoid loss。
- `data_loader.py`: Flickr8k 数据集读取与 dry-run 合成数据。
- `models/resnet_custom.py`: 自定义 ResNet18 图像编码器。
- `models/transformer_encoder.py`: Transformer 文本编码器。
- `models/siglip_model.py`: 组装图像编码器、文本编码器。
- `visualization`: 基于google预训练模型的图文交叉相似度矩阵可视化演示。

代码中带有 `TODO(STUDENT)` 的位置，学生需要自行实现：

- `loss.py` 中 `SigLIPLoss.forward`。
- `models/resnet_custom.py` 中 `BasicBlock` 的卷积、BN、残差连接。
- `models/transformer_encoder.py` 中 `forwad()` 函数。
- `train_siglip.py` 中 `evaluate_retrieval`，评估 Top-K Accuracy / Recall@K (K=1/3/5)检索准确率。
- 需要按照 `visualization` 中 `readme` 的要求进行体验，结合可视化分析模型特性。

数据准备

目录结构建议如下：

```
HW_SigLIP_2026_Student
Flickr8k/
  images/
    *.jpg
  captions.txt
  train_captions.txt
  val_captions.txt
  test_captions.txt
```

快速运行

安装依赖:

```
pip install -r requirements.txt
```

无图片时先做 sanity check:

```
python train_siglip.py --dry-run --epochs 2 --batch-size 32 --num-workers 0
```

有 Flickr8k 图片时训练 **ResNet + Transformer**:

```
python train_siglip.py \  
  --data-dir Flickr8k \  
  --text-encoder transformer \  
  --epochs 20 \  
  --batch-size 64 \  
  --output-dir outputs/resnet_transformer
```

对比一个轻量文本基线:

```
python train_siglip.py \  
  --data-dir Flickr8k \  
  --text-encoder mlp \  
  --epochs 20 \  
  --batch-size 64 \  
  --output-dir outputs/resnet_mlp
```

训练时会保存 **outputs/.../best_siglip.pt** 和每轮覆盖更新的 **outputs/.../latest_siglip.pt**。从已有 checkpoint 继续训练时, **--epochs** 表示最终训练到第几轮; 如果 checkpoint 保存于第 8 轮, 下面命令会从第 9 轮继续训练到第 20 轮:

```
python train_siglip.py \  
  --data-dir Flickr8k \  
  --text-encoder transformer \  
  --epochs 20 \  
  --batch-size 64 \  
  --output-dir outputs/resnet_transformer \  
  --resume outputs/resnet_transformer/latest_siglip.pt
```

建议同学报告最终测试集的 **t2i_R@1/5/10** 和 **i2t_R@1/5/10**, 并说明训练轮数、batch size、学习率、显卡型号。

时间节点

- 5月22日提交中期报告: 中期跑通完整训练流程即可(基于MLP text encoder),
- 6月7日提交最终报告: 完成要求所有内容